



datarisk

DECISION AS A SERVICE

Case Técnico

Contexto do Desafio

Você é cientista de dados na **Datarisk** e está atuando em um projeto para um dos maiores bancos do país, que oferece empréstimos para clientes pessoa física.

O banco busca **reduzir seus índices de inadimplência** e contratou sua equipe para apoiar na construção de uma solução baseada em dados que auxilie na tomada de decisão durante o processo de concessão de crédito.

Seu papel neste projeto é **desenvolver um modelo preditivo** capaz de estimar, **em tempo real**, a **probabilidade de inadimplência** de contratos de crédito solicitados por clientes.

Além da construção do modelo, o banco também espera que você proponha **políticas de crédito** que indiquem como utilizar as previsões geradas para orientar decisões — como aprovar, rejeitar ou ajustar condições de contratos.

Esse ponto é fundamental, pois o banco ainda não possui uma estratégia definida para aplicação do modelo.

Objetivo do Case

O objetivo deste case é que você desenvolva uma solução completa para o banco, composta por:

- Um **modelo preditivo** que estime a **probabilidade de inadimplência** de contratos de crédito solicitados por clientes.
- Uma **política de crédito sugerida** com base nas previsões geradas, indicando como o banco pode utilizar a saída do modelo para tomar decisões.

As previsões devem ser aplicadas aos contratos presentes na base **base_submissao.parquet**, que representa um conjunto de solicitações recentes para as quais o banco deseja tomar decisões mais assertivas.

Para isso, você terá à disposição:

- O **histórico de empréstimos anteriores** dos clientes desde 2017.
- Informações sobre os **pagamentos das parcelas** desses contratos.
- **Dados cadastrais** dos clientes.

O banco deixou a cargo do time de dados a decisão sobre **qual definição de inadimplência utilizar como referência**. Ou seja, você tem liberdade para explorar diferentes formas de definir o que é inadimplência, construir sua própria variável target e **justificar** a escolha feita.

Se você não estiver familiarizado com targets de crédito, algumas abordagens comuns incluem:

- **FPD (First Payment Default)**: atraso na primeira parcela do contrato.
- **EVER30MOB03**: atraso superior a 30 dias em qualquer parcela nos 3 primeiros meses de contrato.
- **OVER60MOB06**: atraso acumulado superior a 60 dias nos 6 primeiros meses de contrato.

Você pode adotar **qualquer definição que considerar adequada**, desde que ela seja construída com os dados disponíveis e faça sentido no contexto do projeto. As sugestões acima são apenas para te dar um direcionamento.

⚠ A forma como você **define** e **justifica** a inadimplência (assim como a política de crédito proposta) será um dos **principais critérios de avaliação** deste case.

Bases de Dados

Você terá acesso a **quatro bases de dados** com informações históricas sobre clientes, contratos de crédito e pagamentos. Essas bases foram extraídas dos sistemas internos do banco e seguem o padrão atualmente utilizado pelas áreas de crédito e risco.

As tabelas se relacionam principalmente por duas chaves:

- **id_cliente**: identifica cada cliente de forma única
- **id_contrato**: identifica cada contrato de crédito realizado

A estrutura esperada de cada base é:

- **base_cadastral.parquet**: reúne dados cadastrais dos clientes, como sexo, estado civil, renda, ocupação, entre outros atributos demográficos e socioeconômicos. Cada linha representa um cliente único (**id_cliente**).
- **base_submissao.parquet**: contém os contratos de crédito que estão em análise no momento, e para os quais o modelo deverá gerar previsões de inadimplência. Cada linha representa o contrato mais recente de um cliente, identificado por **id_cliente**.
- **historico_emprestimos.parquet**: apresenta o histórico de contratos anteriores realizados por cada cliente. Contém informações como valores contratados, status final, tipo de produto, datas e demais dados relevantes. Cada linha representa um contrato específico (**id_contrato**) vinculado a um cliente (**id_cliente**). Um cliente pode ter múltiplos contratos.
- **historico_parcelas.parquet**: detalha os pagamentos realizados para cada contrato, incluindo valores previstos, valores pagos e datas correspondentes. Cada linha representa uma parcela paga de um contrato, vinculada tanto ao **id_contrato** quanto ao **id_cliente**.

Além dessas bases, você receberá um arquivo **dicionario_dados.csv** com a descrição completa de todas as variáveis disponíveis.

⚠ É sua responsabilidade explorar as relações entre essas tabelas, validar a integridade dos dados e construir uma base de modelagem adequada para o desenvolvimento da solução.

Entregáveis

Sua entrega deve conter todos os elementos necessários para **reproduzir a solução** e avaliar as previsões geradas para os contratos da base **base_submissao.parquet**.

Os seguintes itens são esperados:

1. Arquivo com as previsões

Um arquivo **.csv** chamado **submissao_case.csv**, contendo **duas** colunas:

- **id_cliente**
- **probabilidade_inadimplencia**

2. Código-fonte reprodutível

A solução pode ser entregue em qualquer formato (notebook, scripts, etc.), desde que permita **reproduzir o projeto do início ao fim e esteja em Python**.

Recomenda-se incluir:

- Um **requirements.txt** (ou equivalente) com as dependências utilizadas.
- A versão da linguagem de programação.
- Outros arquivos necessários para a execução.

3. Explicação da abordagem

Pode estar no próprio notebook ou em documento separado. Deve abordar:

- A definição da inadimplência (variável target).
- A política de crédito proposta.
- Principais decisões e justificativas relevantes.

A avaliação considerará não apenas os aspectos técnicos da solução, mas também a **clareza**, a **organização** e a **viabilidade de aplicação no contexto real**.

Formato da Submissão

A entrega final deve ser feita por **e-mail**, por meio de um **único** arquivo **.zip**, contendo **todos os arquivos necessários para executar a sua solução**, como mencionado na seção anterior.

⚠ A avaliação será realizada de forma **anônima** para evitar qualquer viés. Por isso, **não inclua seu nome, LinkedIn, GitHub ou qualquer informação pessoal** dentro do conteúdo da solução (códigos, notebooks, pastas, etc.).

⚠ **Não envie nenhuma base de dados**, incluindo bases intermediárias geradas durante o processamento. No entanto, é **imprescindível que seu código permita a reprodução completa dessas bases**, caso elas sejam necessárias para executar o fluxo final da solução.

⚠ Você pode manter sua solução em um repositório pessoal no GitHub, se desejar. No entanto, a **submissão oficial deve ser feita por e-mail no formato solicitado acima**, respeitando as orientações de anonimidade.

Critérios de Avaliação

A solução será avaliada com base em critérios que combinam aspectos técnicos e de negócio. O objetivo é identificar propostas que sejam bem estruturadas, claras, justificadas e aplicáveis ao contexto real de concessão de crédito.

Os **principais** critérios de avaliação são:

- **Definição e justificativa da variável target**
A forma como a inadimplência foi definida e a qualidade da justificativa apresentada terão peso significativo na avaliação.
- **Proposta de política de crédito**
É essencial apresentar uma política de uso clara sobre como utilizar as previsões geradas para orientar decisões reais.
- **Exploração e uso dos dados disponíveis**
Espera-se que você utilize de forma eficiente as informações de empréstimos, pagamentos e perfil dos clientes para extrair valor e construir uma solução robusta.
- **Organização, clareza e reprodutibilidade**
O código deve ser organizado, bem documentado e executável do início ao fim. Soluções não reprodutíveis poderão ser desconsideradas.
- **Viabilidade da solução no mundo real**
O modelo será utilizado em tempo real, no momento da solicitação do empréstimo. Por isso, é importante considerar esse contexto ao desenvolver sua solução.

 **Caso você avance para a próxima etapa, precisará apresentar sua solução. Certifique-se de que todas as decisões estejam bem justificadas e fáceis de explicar.**

Observações Finais

- Você pode utilizar qualquer linguagem, biblioteca ou abordagem que preferir. O mais importante é garantir que sua entrega esteja **completa, funcional e reprodutível**.
- A forma como você organiza e comunica sua solução será considerada na avaliação. **Um código claro, bem estruturado e fácil de entender** é tão importante quanto os resultados obtidos.
- **Este case simula um cenário real**. Tome decisões como se estivesse entregando uma solução pronta para ser aplicada em produção.
- O que mais importa é **como você pensa e estrutura a solução** para o problema de negócio. Aplicar **técnicas simples, bem justificadas e que você domina** é mais valorizado do que usar múltiplos modelos ou abordagens complexas sem domínio claro.
- Entregas incompletas, inconsistentes, que não cumprem algum requisito especificado ou que não possam ser executadas podem ser desclassificadas.

Se tiver qualquer dúvida, **fique à vontade para entrar em contato conosco**.

Boa sorte!